

EST-46111: Fundamentos de Estadística

–Notas de Clase–

Juan Carlos Martínez-Ovando

ITAM

12 de diciembre de 2016

1. Estadística bayesiana no paramétrica

1.1. EBNP: Fundamentos

Preguntas comunes

- ▶ ¿Cuántos grupos hay en un conjunto de datos? ¿Cuántas clases incluir en un modelo de mezclas? (Clasificación no supervisada)
- ▶ ¿Qué función especificar? (Predicción o clasificación supervisada)
- ▶ ¿Cuántos factores considerar empleando reducción de dimensionalidad? (Análisis de factores)

Concepción bayesiana

$$\begin{aligned}y|\theta &\sim F(y|\theta) \\ \theta &\sim \pi(\theta).\end{aligned}$$

Nota que $\pi(\theta)$ en realidad asigna probabilidad al modelo $F(\cdot|\theta)$. i.e.

$$\pi(\theta) \leftrightarrow \pi(F(\cdot|\theta)).$$

1.1. EBNP: Fundamentos

Preguntas comunes

- ▶ ¿Cuántos grupos hay en un conjunto de datos? ¿Cuántas clases incluir en un modelo de mezclas? (Clasificación no supervisada)
- ▶ ¿Qué función especificar? (Predicción o clasificación supervisada)
- ▶ ¿Cuántos factores considerar empleando reducción de dimensionalidad? (Análisis de factores)

Concepción bayesiana

$$\begin{aligned}y|\theta &\sim F(y|\theta) \\ \theta &\sim \pi(\theta).\end{aligned}$$

Nota que $\pi(\theta)$ en realidad asigna probabilidad al modelo $F(\cdot|\theta)$. i.e.

$$\pi(\theta) \leftrightarrow \pi(F(\cdot|\theta)).$$

1.1. EBNP: Fundamentos

Concepción bayesiana no paramétrica (densidad)

Entonces, por qué no adoptar directamente lo siguiente

$$\begin{aligned}y|F &\sim F(y) \\ F &\sim \pi(F).\end{aligned}$$

Concepción bayesiana no paramétrica (regresión)

De igual forma, por qué no adoptar directamente lo siguiente

$$\begin{aligned}y|f &\sim N(y|f, \lambda) \\ f &\sim \pi(f).\end{aligned}$$

1.1. EBNP: Fundamentos

Concepción bayesiana no paramétrica (densidad)

Entonces, por qué no adoptar directamente lo siguiente

$$\begin{aligned}y|F &\sim F(y) \\ F &\sim \pi(F).\end{aligned}$$

Concepción bayesiana no paramétrica (regresión)


De igual forma, por qué no adoptar directamente lo siguiente

$$\begin{aligned}y|f &\sim N(y|f, \lambda) \\ f &\sim \pi(f).\end{aligned}$$

1.2. EBNP: Mezcla de modelos

Clasificación no supervisada

Figura: Formación e identificación de clusters



1.2. EBNP: Mezcla de modelos

Proceso Dirichlet

Se define como una distribución sobre un espacio de distribuciones (i.e. medida de probabilidad sobre medidas de probabilidad)

Si G es la función de distribución sobre \mathcal{X} , tenemos

$$G \sim \text{DP}(G|G_0, \alpha), \quad (1)$$

donde

- ▶ G_0 es una medida de probabilidad absolutamente continua
- ▶ α es un escalar positivo.

Comentarios

Para toda partición (A_1, \dots, A_n) de \mathcal{X} ,

$$(G(A_1), \dots, G(A_n)) \sim \text{Dir}(\alpha G_0(A_1), \dots, \alpha G_0(A_n)). \quad (2)$$

1.2. EBNP: Mezcla de modelos

Proceso Dirichlet

Se define como una distribución sobre un espacio de distribuciones (i.e. medida de probabilidad sobre medidas de probabilidad)

Si G es la función de distribución sobre \mathcal{X} , tenemos

$$G \sim \text{DP}(G|G_0, \alpha), \quad (1)$$

donde

- ▶ G_0 es una medida de probabilidad absolutamente continua
- ▶ α es un escalar positivo.

Comentarios

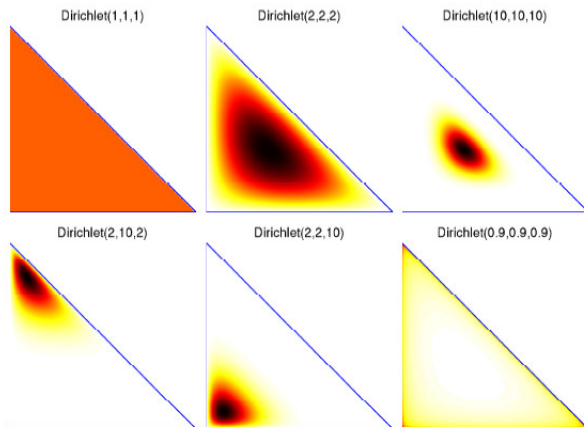
Para toda partición (A_1, \dots, A_n) de \mathcal{X} ,

$$(G(A_1), \dots, G(A_n)) \sim \text{Dir}(\alpha G_0(A_1), \dots, \alpha G_0(A_n)). \quad (2)$$

1.2. EBNP: Mezcla de modelos

Proceso Dirichlet

Figura: Asignación de distribuciones iniciales



1.2. EBNP: Mezcla de modelos

Proceso Dirichlet (forma)

Si G es un proceso Dirichlet, entonces,

$$G(\theta) = \sum_{i=1}^{\infty} \omega_i \delta_{\theta_i^*}(\theta), \quad (3)$$

donde

- ▶ $(\omega_i)_{i=1}^{\infty}$ se definen en el simpler de dimensión infinita
- ▶ $(\theta_i^*)_{i=1}^{\infty}$ son átomos aleatorios distintos definidos en Θ .

Se tiene que si θ_i s son iid de G_0 entonces $\mathbb{E}(G) = G_0$.

Proceso Dirichlet (conjugacidad)

Si $G \sim \text{DP}(G|G_0, \alpha)$ y $\theta_1, \dots, \theta_n$ son una m.a. de G , entonces

$$G|\theta_1, \dots, \theta_n \sim \text{DP} \left(\frac{\alpha}{\alpha + n} G_0 + \frac{1}{\alpha + n} \sum_{j=1}^n \delta_{\theta_j}, \alpha + n \right). \quad (4)$$

1.2. EBNP: Mezcla de modelos

Proceso Dirichlet (forma)

Si G es un proceso Dirichlet, entonces,

$$G(\theta) = \sum_{i=1}^{\infty} \omega_i \delta_{\theta_i^*}(\theta), \quad (3)$$

donde

- ▶ $(\omega_i)_{i=1}^{\infty}$ se definen en el simplex de dimensión infinita
- ▶ $(\theta_i^*)_{i=1}^{\infty}$ son átomos aleatorios distintos definidos en Θ .

Se tiene que si θ_i s son iid de G_0 entonces $\mathbb{E}(G) = G_0$.

Proceso Dirichlet (conjugacidad)

Si $G \sim \text{DP}(G|G_0, \alpha)$ y $\theta_1, \dots, \theta_n$ son una m.a. de G , entonces

$$G|\theta_1, \dots, \theta_n \sim \text{DP} \left(\frac{\alpha}{\alpha + n} G_0 + \frac{1}{\alpha + n} \sum_{j=1}^n \delta_{\theta_j}, \alpha + n \right). \quad (4)$$

1.2. EBNP: Mezcla de modelos

Mezcla de proceso Dirichlet (forma)

Si \mathcal{X} es el soporte de una variable aleatoria observable y G es un proceso Dirichlet sobre un espacio parametral no observable θ , entonces,

$$\begin{aligned}P(x) &= \int_{\theta} N(x|\theta) G(d\theta) \\&= \sum_{i=1}^{\infty} \omega_i N(x|\theta_i^*) \\&= \sum_{i=1}^{\infty} P(s=i|\boldsymbol{\omega}) N(x|\theta_i^*, s=i),\end{aligned}$$

donde $\mathbf{s} = (s_1, \dots, s_K, \dots)$ dado $\boldsymbol{\omega}$ es multinomial, y las $\boldsymbol{\omega} = (\omega_1, \dots, \omega_K, \dots)$ son Dirichlet (por lo que la conjugacidad se sigue).

Mezcla del proceso Dirichlet (clasificación)

Dada una muestra de datos, x_1, \dots, x_n se derivan probabilidades de clasificación

$$P(s^{(j)} = i | \mathbf{s}_{-j}, \boldsymbol{\omega}) = \begin{cases} \frac{n-j, i}{\alpha + (n-1)}, & \text{si } i \text{ es representado} \\ \frac{\alpha}{\alpha + (n-1)}, & \text{si } i \text{ no es representado} \end{cases} \quad (5)$$

1.2. EBNP: Mezcla de modelos

Mezcla de proceso Dirichlet (forma)

Si \mathcal{X} es el soporte de una variable aleatoria observable y G es un proceso Dirichlet sobre un espacio parametral no observable θ , entonces,

$$\begin{aligned}P(x) &= \int_{\theta} N(x|\theta) G(d\theta) \\&= \sum_{i=1}^{\infty} \omega_i N(x|\theta_i^*) \\&= \sum_{i=1}^{\infty} P(s=i|\boldsymbol{\omega}) N(x|\theta_i^*, s=i),\end{aligned}$$

donde $\mathbf{s} = (s_1, \dots, s_K, \dots)$ dado $\boldsymbol{\omega}$ es multinomial, y las $\boldsymbol{\omega} = (\omega_1, \dots, \omega_K, \dots)$ son Dirichlet (por lo que la conjugacidad se sigue).

Mezcla del proceso Dirichlet (clasificación)

Dada una muestra de datos, x_1, \dots, x_n se derivan probabilidades de clasificación

$$P(s^{(j)} = i | \mathbf{s}_{-j}, \boldsymbol{\omega}) = \begin{cases} \frac{n-j, i}{\alpha + (n-1)}, & \text{si } i \text{ es representado} \\ \frac{\alpha}{\alpha + (n-1)}, & \text{si } i \text{ no es representado} \end{cases} \quad (5)$$

1.2. EBNP: Mezcla de modelos

Mezcla de proceso Dirichlet (inferencia)


Se requieren métodos computacionales para estimar (inferir) y predecir en esta clase de modelos.

- ▶ *Gibbs sampling* (e.g. Escobar y West, 1995; Neal, 2000; Rasmussen, 2000)
- ▶ *Variational approximation* (Blei y Jordan, 2005)
- ▶ *Expectation propagation* (Minka y Ghahramani, 2003)
- ▶ *Hierarchical clustering* (Heller y Ghahramani, 2005)
- ▶ y muchos otros...

1.3. EBNP: Estimación de curvas

Suavizamiento

Figura: Curvas de respuesta



1.3. EBNP: Estimación de curvas

Proceso gaussiano

Supongamos que los datos toman valores en \mathcal{X} y deseamos estimar una curva de respuesta $f : \mathcal{X} \rightarrow \mathbb{R}$, de tal forma que f es nuestro parámetro de interés.

Proceso gaussiano(definición)

Se dice que f es un proceso gaussiano si para todo x_1, \dots, x_n se sigue

$$P(f(x_1), \dots, f(x_n)) = N_n((f(x_1), \dots, f(x_n)) | (\mu(x_1), \dots, \mu(x_n)), \Sigma_n), \quad (6)$$

donde

- ▶ μ es una función media y
- ▶ Σ es una función de covarianza.

1.3. EBNP: Estimación de curvas

Proceso gaussiano

Supongamos que los datos toman valores en \mathcal{X} y deseamos estimar una curva de respuesta $f : \mathcal{X} \rightarrow \mathbb{R}$, de tal forma que f es nuestro parámetro de interés.

Proceso gaussiano(definición)

Se dice que f es un proceso gaussiano si para todo x_1, \dots, x_n se sigue

$$P(f(x_1), \dots, f(x_n)) = \mathbf{N}_n((f(x_1), \dots, f(x_n)) | (\mu(x_1), \dots, \mu(x_n)), \mathbf{\Sigma}_n), \quad (6)$$


donde

- ▶ μ es una función media y
- ▶ Σ es una función de covarianza.

1.3. EBNP: Estimación de curvas

Proceso gaussiano

Figura: Procesos gaussianos con diferentes funciones de covarianza



1.3. EBNP: Estimación de curvas


Proceso gaussiano (regresión)

Para los datos $\{(y_i, x_i)\}_{i=1}^n$, se puede definir

$$\begin{aligned} y_i | f, x_i &\sim \mathcal{N}(y_i | f(x_i), \lambda) \\ f &\sim \text{GP}(f | 0, \Sigma) \end{aligned}$$

Proceso gaussiano (muestras de la prior)

Figura: Simulación de distribuciones iniciales



1.3. EBNP: Estimación de curvas


Proceso gaussiano (regresión)

Para los datos $\{(y_i, x_i)\}_{i=1}^n$, se puede definir

$$\begin{aligned} y_i | f, x_i &\sim \mathcal{N}(y_i | f(x_i), \lambda) \\ f &\sim \text{GP}(f | 0, \Sigma) \end{aligned}$$

Proceso gaussiano (muestras de la prior)

Figura: Simulación de distribuciones iniciales



1.3. EBNP: Estimación de curvas


Proceso gaussiano (predicción)

Para los datos $\text{datos} = \{(y_i, x_i)\}_{i=1}^n$, la distribución predictiva es,

$$P(y_f | f, x_f, \text{datos}) = \int \mathcal{N}(y_f | f(x_f), \lambda) \text{GP}(\text{d}f | \text{datos})$$

Proceso gaussiano (muestras de la posterior)

Figura: Predicción de procesos gaussianos



1.3. EBNP: Estimación de curvas


Proceso gaussiano (predicción)

Para los datos $\text{datos} = \{(y_i, x_i)\}_{i=1}^n$, la distribución predictiva es,

$$P(y_f | f, x_f, \text{datos}) = \int \mathbf{N}(y_f | f(x_f), \lambda) \text{GP}(\text{d}f | \text{datos})$$

Proceso gaussiano (muestras de la posterior)

Figura: Predicción de procesos gaussianos



1.3. EBNP: Estimación de curvas

Proceso gaussiano

Los procesos gaussianos se emplean en diferentes contextos

- ▶ Regresión (estimación)
- ▶ Regresión (predicción)
- ▶ Regresión (clasificación supervisada)
- ▶ Optimización bayesiana
- ▶ Series de tiempo

1.4. EBNP: Discusión

Discusión

- ▶ En ocasiones, se requieren distribuciones iniciales flexibles. Los modelos no paramétricos proporcionan una manera de definir modelos flexibles.
- ▶ Muchos modelos no paramétricos pueden derivarse partiendo de modelos paramétricos finitos y tomando el límite cuando el número de parámetros va al infinito.
- ▶ Los modelos no paramétricos pueden implementarse en la práctica con relativa facilidad.
- ▶ Hemos revisado los procesos gaussianos y los procesos de Dirichlet. Aún hay una gama extensa de modelos no paramétricos por explorar.

¡Gracias por su paciencia!

`juan.martinez.ovando@itam.mx`